

Counterfactuals i Python

Implementering av DiCE
på folkhälsodata

Elev: Jesper Anteryd
uppdragsgivare: Håkan Lane
Kurs: Examensarbete
Handledare: Ammar Alnahas
Utbildning: Python mot AI
Ort, datum: Göteborg, VT 2026

Sammanfattning

Studien undersöker hur python-ramverket DiCE generar counterfactual explanations (CFs) för folkhälsodata från European Social Survey. Syftet är att analysera vilka kombinationer av prediktionsmodeller, algoritmer (explainers) och parameterinställningar som ger valida genomförbara och meningsfulla CF-förslag för livsstilsvariabler kopplade till hjärt-kärlssjukdom.

Två prediktionsmodeller används: Random Forest (RF) och XGBoost (XGB). Tre experimentfaser genomförs:

1. baseline-modeller med olika explainers och constraints,
2. modeller optimerade med SMOTE och klassviktning,
3. baseline-modeller testade mot olika nivåer av stopping_threshold.

Resultaten vid fas 1 visar att constraints är nödvändiga vid CF-generering. RFs har lättare att med små förändringar ge större riskreduktioner, medan XGB kräver större justeringar. Den genetiska explainern är både snabbare och ger bättre CFs.

I fas 2 visar SMOTE och klassviktning att metoder som förbättrar klassificeringsprestanda kan försämra CF-generering, eftersom de skapar instabila och artificiellt uppdragna sannolikheter. Viktigare för DiCE är jämnare och mer förutsägbara prediktioner.

Fas 3 visar att stopping_threshold fungerar som ett praktiskt test av modellernas kalibrering och sannolikhetsstruktur. stopping_threshold avgör om en CF kan hittas, men hur stora förändringar som krävs beror på modellens sannolikhetsstruktur. XGB är mer förutsägbar, medan RF gör större hopp - vilket hjälper RF vid lägre stopping_thresholds.

Studien identifierar flera metodologiska begränsningar, bland annat att BMI dominerar både prediktioner och CF-förslag, att vissa variabler är praktiskt opåverkbara, och att Gower-distansen inte fångar verklig beteendemässig betydelse. För framtida arbete föreslås förbättrade constraints, dynamiska stopping_threshold-värden och mer domänspecifik modellering.

Innehållsförteckning

1. Inledning.....	1
1.1 Bakgrund och Syfte.....	1
1.2 Problemformulering, frågeställning och avgränsning.....	1
2. Metod.....	2
2.1 Databeskrivning.....	2
2.2 Ramverket DiCE.....	3
2.3 Prediktionsmodeller.....	4
2.4 Experimentmiljö.....	4
2.5 Utvärderingsmått.....	5
2.5.1 Validitet, beräkningstid och genomförbarhet.....	5
2.5.2 Proximity, Sparsity, Diversity.....	5
2.6 Modellens kalibrering, stabilitet och stopping_threshold.....	6
2.7 Experimentdesign.....	6
2.7.1 Design, fas 1: utforskning av baseline-modeller, explainers och constraints.....	6
2.7.2 Design, fas 2: Modelloptimering via SMOTE och viktning.....	7
2.7.3 Design, fas 3: Prediktionsmodeller mot stopping_threshold.....	7
3. Resultat.....	8
3.1 Resultat, fas 1: baseline-modeller och utforskning.....	8
3.2 Resultat, fas 2: Modelloptimering via SMOTE och viktning.....	9
3.3 Resultat, fas 3: Prediktionsmodeller mot stopping_threshold.....	11
4. Diskussion.....	12
4.1 Constraints och explainers.....	12
4.2 Modellernas sannolikhetsstruktur (bagging vs boosting).....	12
4.3 Effekten av datamanipulation på sannolikheter.....	14
4.4 Effekten av stopping_threshold.....	15
4.5 Metodologiska problem och begränsningar.....	16
4.6 Vidare utveckling.....	18
Referenser.....	19
Tack.....	20
Appendix A. Variabelbeskrivningar, skalor och observationer.....	21
Appendix B. Experimentmiljö och system-konfiguration.....	23
Appendix C. Körningar för Generation 1.....	24

1. Inledning

Människor tänker ofta i ”tänk-om...” banor. Vi föreställer oss alternativa scenarier: *tänk om jag hade tränat mer, tänk om jag hade valt en annan väg, tänk om jag hade sovit bättre*. Denna typ av resonemang kallas *counterfactual thinking* och är välstuderad inom psykologin.

Inom artificiell intelligens använder vi en liknande idé när vi försöker förstå hur en modell fattar beslut. Genom att fråga *vad som hade behövt ändras för att modellen skulle ge ett annat resultat* kan vi skapa så kallade **counterfactual explanations**. Den formella teorin bakom kontrafaktiska resonemang utvecklades bland annat av Lewis (1975).

I denna rapport fokuserar vi på praktiska tillämpningar inom maskininlärning och Python. Mer specifikt studeras counterfactuals inom hälsoområdet baserat på enkätdata insamlad inom EU. Datasetet innehåller frågor om hälsa, livsstil, attityder, och demografi. Det har gjorts ett urval av variabler och studien använder en binär målvariabel som indikerar förekomst av hjärt-kärlsjukdom. Counterfactuals (CF) kan här användas för att besvara frågor som: *Hur många dagar i veckan hade personen behövt träna för att minska sin risk?* eller *Vilken minimal förändring i livsstil skulle modellen acceptera för att ändra sitt beslut?*

1.1 Bakgrund och Syfte

Forskningen inom Explainable AI (XAI) har under de senare år utvecklat flera metoder för att förklara maskininlärningsmodeller, där counterfactual explanations utgör en central del. Wachter et al (2017) introducerade tidigt kontrafaktiska förklaringar som ett sätt att beskriva vilka minimala förändringar som krävs för att en modell ska ändra sitt beslut. På den praktiska sidan har DiCE-biblioteket (Mothilal et al. 2020) bidragit med ett av de mest använda Python-biblioteken för generering av CFs.

Denna studie genomförs inom ramen för en tre månader lång praktikperiod och utgör en delstudie i Nightingale-initiativet, där olika bibliotek för CF-generering jämförs mellan Python och R. I föreliggande rapport avgränsar vi oss dock till Python-miljön och fokuserar specifikt på biblioteket DiCE. Andra relevanta paket, såsom Alibi, inkluderas inte på grund av tidsbegränsningar.

1.2 Problemformulering, frågeställning och avgränsning

Det övergripande målet är att undersöka hur olika CF-algoritmer presterar avseende validitet, genomförbarhet och beräkningstid. Studien är avgränsad till Python-ramverket DiCE och omfattar endast två prediktionsmodeller: Random Forest och XGBoost. Andra paket och implementationer, såsom Alibi eller R-paketet Dandl, analyseras inte här. Fokus i denna studie ligger på en experimentell genomgång av DiCE:s beteende.

Den centrala frågeställningen lyder:

Vilka kombinationer av counterfactual-algoritmer, prediktionsmodeller och parameterinställningar ger de mest valida, genomförbara och meningsfulla counterfactual-förändringarna för livsstilsrelaterade variabler?

För att operationalisera huvudfrågan delas den upp i tre delfrågor:

1. Hur påverkar olika baseline-inställningar och CF-algoritmer resultatens validitet, genomförbarhet och beräkningstid?
2. Hur påverkar modelloptimeringar (t.ex. SMOTE och viktning) kvaliteten på genererade CFs?
3. Hur samspelar parametern `stopping_threshold` med modellernas kalibrering för att uppnå validitet vid generering av CFs?

2. Metod

2.1 Databeskrivning

I detta projekt användes data från ett EU-undersökning, *The European Social Survey* (ESS version 11, upplaga 3.0). ESS samlar nationellt representativa data angående attityder, beteenden och sociodemografiska kännetecken från alla EU-länder. Datasetet innehåller flera livsstilsvariabler samt mått på hälsa. De flesta av de utvalda kännetecknen är surveydata som fångar frekvens av frukt- och grönsakskonsumtion, alkoholkonsumtion, rökning och sömnproblem. En kontinuerlig variabel mäter body mass index (BMI), och en binär mäter bullerexponering i hemmiljön. Avslutningsvis används en binär diagnostisk målvariabel: förekomst av hjärt-kärlsjukdom.

Tabell 2.1. Variabelbeskrivningar

Namn	Beskrivning	Skala	Typ
etfruit	Frekvens - äta frukt	1–7 (1 = ofta, 7 = aldrig)	Prediktor
eatveg	Frekvens - äta grönsaker	1–7 (1 = ofta, 7 = aldrig)	Prediktor
cgtsmok	Frekvens - Rökning (cigaretter)	1–6 (1 = mycket, 6 = aldrig)	Prediktor
alcfreq	Frekvens - Alkoholkonsumtion	1–7 (1 = ofta, 7 = aldrig)	Prediktor
slprl	Frekvens - Sömnproblem	1–4 (1 = aldrig, 4 = alltid)	Prediktor
dosport	Träning, dagar per vecka	0-7	Predictor
BMI	Body mass index	Kontinuerlig variabel	Prediktor
paccnois	Bullerexponering i hemmiljön	Binär	Prediktor
hltp rhc	Hjärt-kärlsjukdom	Binär	målvariabel

Flera sociologiska variabler och andra livsstilsvariabler från datasetet övervägdes för inkludering i projektet – så som sociala möten (frekvens), upplevd diskriminering, upplevd kontroll över livet samt självuppskattad hälsa. Även om dessa faktorer i sig var intressanta och ger värdefull kontextuell information, fann vi dem inte vara genomförbara vad gäller designen kring CFs för projektet. Tabell 2.1 visar en översikt av utvalda variabler ur ESS-datan. För en mer utförlig redogörelse för hur skalor och värden är kodade, se appendix A.

Datasetet innehåller 41105 observationer. I förbehandlingen filtrerades datapunkter med eventuella fel och saknade värden. Därefter delades datasetet upp i en träningsmängd (80%) och en testmängd

(20%) för att träna och utvärdera den underliggande maskininlärningsmodellen. En stratifierad uppdelning har använts för att bevara fördelningen av klasser hos målvariabeln. Målvariabeln är kraftigt obalanserad, med ungefär ett 10:1-förhållande mellan negativa (hälsosamma) och positiva fall (hjärt- och kärlsjukdom). Även om datasetet är representativt för populationen innebär den kraftigt obalanserade klassfördelningen att modellerna får begränsad förmåga att generalisera till positiva fall (hjärt-kärlsjukdom).

Ett urval av nio observationer har gjorts för CF-experimenten som följer nedan, vilket återfinns i Appendix A. Eftersom syftet med studien är att analysera modellernas beteende i CF-generering, snarare än att dra statistiska slutsatser om en population, är ett litet antal observationer tillräckligt.

2.2 Ramverket DiCE

DiCE (Diverse Counterfactual Explanations) är ett Python-baserat ramverk för att generera counterfactuals för maskininlärningsmodeller. Ramverket är utvecklat inom InterpretML-projektet och är ett av få verktyg som explicit fokuserar på att producera flera alternativa och mångsidiga CF-förslag för samma individ. DiCE fungerar som ett lager ovanpå befintliga modeller och använder deras prediktionsfunktioner för att söka efter förändringar i input-variabler som leder till ett önskat utfall.

Tabellen nedan visar ett förenklat exempel av studiens resultat. Tabellen innehåller en ursprunglig observation med tre valida CFs. Variabelnamnen har förenklats för läsbarhet. Exemplet visar hur olika CF-förslag kan vara, trots att de alla leder till en riskreduktion.

Tabell 2.2: Exempel på DiCE-output

CF_id	fruit	veg	smoking	alcfreq	sleep	noise	dosport	BMI
Ursprunglig observation	4	3	3	4	2	0	0	18.9
CF 1								16.7
CF 2	3							16.4
CF 3				7			7	

I CF 1 sker endast en förändring: BMI minskar från 18.9, till 16.7. Även om detta tekniskt sett är en valid CF, väcker det frågor om rimlighet och genomförbarhet. I CF 3 föreslås istället en kombination av minskad alkoholkonsumtion (inverterad skala) och kraftigt ökad fysisk aktivitet, vilket representerar en betydligt större livsförändring. Dessa exempel illustrerar några av de centrala frågor som studien adresserar: hur olika modeller, constraints och sannolikhetsstrukturer påverkar vilka typer av CF-förslag som genereras, och i vilken utsträckning dessa förslag är realistiska eller användbara i praktiken. Studien är därför utforskande i sin karaktär och gör inte anspråk på att ge rekommendationer, utan syftar till att belysa mekanismer och mönster i CF-genereringen.

DiCE stödjer flera olika back-ends, så som *Scikit-learn* och *Tensorflow*, och tillhandahåller flera interna modeller eller algoritmer för att generera counterfactuals. I ramverket kallas dessa algoritmer för *explainers*, så i fortsättningen används därför samma begrepp i den här studien. De explainers som erbjuds är *random-search*, *genetic* och en *gradient*-baserad explainer. Den gradientbaserade explainern är avsedd för neurala nätverk och testades initialt med en enkel linjär Keras-modell men kombinationen gav inga lovande resultat. På grund av tidsbegränsningar utforskades den därför inte vidare.

Tabell 2.3: Parametrar för DiCE-explainers

Explainer	Parameter	Beskrivning
Alla	total_cfs	Antal counterfactuals som ska genereras
Alla	desired_class	Målkategori för counterfactuals
Alla	features_to_vary	Lista över features som får ändras
Alla	permitted_range	Tillåtna intervall för feature-värden
Alla	posthoc_sparsity_param	Styr hur sparsamma counterfactuals ska vara
Alla	posthoc_sparsity_algorithm	Algoritm för sparsitet (t.ex ”linear”)
Alla	stopping_threshold	Tröskel för när optimeringen avbryts
Random	random_seed	Slumpfrö för reproducerbarhet
Genetic	Maxiterations	Antal generationer i den genetiska explainern

DiCE-explainers delar ett antal centrala parametrar som styr hur CFs genereras. Tabell 2.2 sammanfattar de viktigaste inställningarna. **Total_cfs** sattes på 10 som default. Parametern **desired_class** sattes till 0, vilket innebär att DiCE försöker generera CFs som ML-modellen bedömer som låg risk. **features_to_vary** kan användas för att låsa variabler som inte bör ändras, exempelvis demografiska attribut. **permitted_range** (vi använder även begreppet constraints i fortsättningen) användes för att styra riktningen på förändringar och förhindra orimliga förslag. Parametern **stopping_threshold** behandlas mer utförligt i avsnitt 2.6. Slutligen används **random_seed** för reproducerbarhet i random-search-explainern, och **maxiterations** styr hur många generationer den genetiska explainern får utföra.

2.3 Prediktionsmodeller

Tre typer av prediktionsmodeller testades i studien: Random Forest, XGBoost, och ett enkelt neuralt nätverk. Random Forest-modellen (RF) tränades med standardnära hyperparametrar (300 träd, obegränsat djup, minsta bladstorlek 5) och uppnådde hög övergripande *accuracy* men låg ROC-AUC och låg *recall* för minoritetsklassen. Trots detta visade sig RF vara lovande för att generera valida CFs. XGBoost (XGB) användes som ett alternativ som förväntades hantera klassobalans bättre. Baseline-modellen (300 estimatorer) uppvisade liknande svårigheter att identifiera positiva utfall, men gav ändå tillräckligt stabila sannolikheter för att vara användbar i CF-genereringen.

De modeller som beskrivs ovan utgör studiens baseline-modeller. Ytterligare modellvarianter, inklusive hyperparameteroptimerade och klassviktade versioner, introduceras förs i experiment designen (avsnitt 2.6).

2.4 Experimentmiljö

Experimenten kördes i en isolerad Python-miljö med Python 3.11.13. En fullständig redogörelse för hårdvara, systemkonfiguration och paketlista finns i Appendix B.

AI-baserat skrivstöd (Microsoft Copilot) har använts för språklig förbättring och strukturering av text. Allt innehåll i rapporten baseras på författarens experiment. AI-verktyget har inte genererat data, resultat eller metodbeslut, utan enbart fungerat som ett språkligt stöd. All kod och samtliga experiment finns dokumenterade i författarens publika Git-repository för att möjliggöra full reproducerbarhet.

2.5 Utvärderingsmått

2.5.1 Validitet, beräkningstid och genomförbarhet

I denna studie definieras **validitet** som att en genererad counterfactual måste minska modellens predicerade risk (dvs. modellens sannolikhetsestimater) med minst 50 procent. Riskvärdet baseras helt på prediktionsmodellens interna sannolikhetsstruktur och inte på det faktiska utfallet. Prediktionsmodellerna är tränade på kraftigt obalanserade data, vilket gör att riskvärdena ofta ligger långt under den nivå som skulle krävas för ett formellt klassbyte. Ett relativt mål – halveringsmålet – är därför mer robust, mindre känsligt för modellens kalibrering.

Beräkningshastighet är ytterligare ett mått, eftersom CF-generering kräver tusentals upprepade prediktioner påverkar även modellens beräkningshastighet den totala körtiden. Små skillnader i prediktionstid ackumuleras snabbt.

Som illustrerades kort i 2.2 är det även centralt att mäta en CFs **Genomförbarhet** (eng. *feasibility*). Utan constraints tenderar DiCE att föreslå förändringar som är matematiskt effektiva men praktiskt orimliga, så som att öka alkoholkonsumtion eller BMI. Genom att införa riktade constraints - en implementation av `permitted_range` - förbättras genomförbarheten avsevärt. I fortsättningen används begreppet constraints för denna riktade implementation.

2.5.2 Proximity, Sparsity, Diversity

DiCE bygger på tre centrala kvalitetsmått för CFs: *proximity*, *sparsity* och *diversity*.

Proximity beskriver hur nära originalobservationen en CF ligger. DiCE optimerar detta automatiskt genom att minimera avståndet i feature-rummet. I denna studie kompletterades detta med Gower-distance i efterbearbetningen, för att kunna välja den mest rimliga CFs bland flera valida alternativ.

Sparsity avser hur få variabler som ändras i en CF. Få förändringar är ofta att föredra, särskilt i en folkhälsokontext där slutanvändare behöver kunna förstå och agera på förslagen. Vi har inkluderat DiCE:s *sparsity*-parameter i våra inställningar, men på grund av tidsramen har inga systematiska experiment genomförts med olika *sparsity*-nivåer.

Diversity syftar på att generera flera olika typer av CF, snarare än många variationer av samma lösning. Detta är särskilt relevant eftersom vi ibland observerade att modellerna fastnade i ensidiga lösningar, ofta dominerade av BMI. En högre grad av *diversity* skulle möjliggöra att presentera flera alternativa lösningar för en individ, men en fullständig analys av detta ligger utanför studiens omfattning.

Sammanfattningsvis utforskar denna studie dessa begrepp på en grundläggande nivå, med fokus på hur de påverkades av prediktormodeller, explainers och `stopping_threshold` i relation till ett obalanserat dataset.

2.6 Modellens kalibrering, stabilitet och stopping_threshold

För att generera CFs testar DiCE många små förändringar i en observation och utvärderar hur modellen reagerar. Detta innebär att modellens sannolikhetsbeteende är avgörande för hur effektivt CF-sökningen fungerar. Traditionella prestandamått som *accuracy* och *ROC-AUC* fångar inte detta, eftersom de beskriver klassificeringsförmåga snarare än hur sannolikheten förändras vid små variationer i input.

Tre egenskaper är därför centrala:

- **Kalibrering:** beskriver om modellen generellt producerar höga eller låga riskvärden. I ett obalanserat dataset, som i denna studie, ger modeller ofta låga sannolikheter för de flesta observationer, vilket påverkar hur långt riskvärdet måste sänkas för att uppnå validitet.
- **Sannolikhetsstruktur:** avser hur modellens predicerade sannolikhet förändras när input ändras. RF ger ofta stegvisa hopp eftersom varje träd delar upp datan i diskreta regioner, medan XGB ändrar sannolikheten gradvis genom små korrigeringar.
- **Stabilitet:** Beskriver hur förutsägbara dessa sannolikhetsförändringar är. En stabil model ger små och konsekventa förändringar i riskvärdet när input förändras, medan en instabil model kan reagera med stora eller oregelbundna hopp.

Utöver dessa egenskaper används även DiCE:s parameter **stopping_threshold**. Den anger hur låg risk en genererad CF måste ha för att vi ska acceptera den. Om **stopping_threshold** exempelvis sätts på 0.9 innebär det att modellen måste bedöma den nya observationen som minst 90% sannolik att tillhöra lågrisk-gruppen. Eftersom modellen bara har två möjliga utfall innebär detta samtidigt att sannolikheten för högrisk måste vara lägre än 10%. **Stopping_threshold** fungerar därmed som ett absolut mål som är gemensamt för alla observationer, oavsett deras ursprungliga risknivå.

I denna studie används **stopping_threshold** tillsammans med ett relativt mål: att riskvärdet ska halveras jämfört med originalobservationen. Kombinationen av ett **relativt mål** (halvering av risk) och ett **absolut mål** (**stopping_threshold**) innebär att kriterierna ibland samverkar och ibland står i konflikt, beroende på modellernas kalibrering och observation.

2.7 Experimentdesign

2.7.1 Design, fas 1: utforskning av baseline-modeller, explainers och constraints.

Denna fas adresserade främst delfråga 1, och följde en 2x2x2-design där två explainers (Random-search och genetisk), två prediktionsmodeller (RF och XGB) kombinerades med och utan constraints. Syftet var att identifiera centrala mönster, begränsningar och känsligheter i CF-genereringen. I denna fas användes baseline-modeller med standardparametrar (300 träd) och följande DiCE-inställningar:

- `total_CFs = 10`
- `stopping_threshold = 0.9`
- `posthoc_sparsity_param = 0.1`
- `maxiterations (genetic) = 500`

Constraints användes för att styra vilka förändringar som är rimliga (t.ex. att rökning endast får minska). Som jämförelse testades även en efterbearbetningsstrategi där fler CFs genererades och

sedan filtrerades, men denna metod visade sig mindre förutsägbar än att använda constraints direkt i optimeringen.

I efterbearbetningen valdes slumpmässigt en CF som både var valid och genomförbar. Om ingen sådan fanns, valdes den första CF som var valid.

2.7.2 Design, fas 2: Modelloptimering via SMOTE och viktning

Fas två adresserade främst delfråga 2, och undersökte hur strategier för modelloptimering som används för att förbättra klassificeringsprestanda - såsom klassviktning och syntetisk balansering via SMOTE - påverkar möjligheten att generera valida counterfactuals. Dessa metoder kan vara motiverade i klassificeringsproblem, men kritiseras i sammanhang där sannolikhetsnivåer och kalibrering är viktiga, eftersom syntetisk balansering och viktning leder till sannolikheter som inte speglar den ursprungliga datastrubutionen. Dock är det relevant att undersöka hur sådana förändringar i modellens riskvärden påverkar CF-sökningen. Syftet med denna fas är därför inte att förbättra klassificeringsprestanda, utan att analysera hur dessa optimeringsstrategier påverkar modellens beteende i CF-generering.

Tre optimeringsstrategier utvärderades:

1. Hyperparameteroptimerade modeller med klassviktning
2. Baseline-modeller tränade på syntetiskt balanserad data (SMOTE)
3. Hyperparameteroptimerade modeller tränade på SMOTE-data

I denna fas användes endast den genetiska explainern med constraints, eftersom dessa visade bäst balans mellan validitet, genomförbarhet och beräkningstid i fas 1. För varje observation genererades 10 rekommendationer. Det gjordes försök att generera CFs mot olika nivåer av `stopping_threshold` (0.1, 0.5 och 0.9), Vilket i flera fall misslyckades, även om viss variation förekom.

Hyperparameteroptimeringar genomfördes med `RandomizedSearchCV` i två steg: först en bred parametersökning, därefter en snävare sökning kring de kombinationer som gav stabila resultat.

2.7.3 Design, fas 3: Prediktionsmodeller mot `stopping_threshold`

Fas tre adresserade delfråga 3, och undersökte hur enklare prediktionsmodeller påverkar möjligheten att generera valida CF vid olika nivåer av `stopping_threshold` (0.1, 0.5 och 0.9). De modeller som inkluderades var baseline-versionerna av RF samt XGB, eftersom dessa tidigare visat stabil prestanda i fas 1.

En tredje modell inkluderades: en XGB-variant tränad via `RandomizedSearchCV` men utan viktning eller träning på översamplad data (SMOTE). Modellen har en likvärdig prediktionsprestanda som baseline-XGB, men inkluderades för att undersöka om förändringar i hyperparametrarna påverkar beteendet vid CF-generering. Designen kombinerar tre prediktionsmodeller med tre nivåer av `stopping_threshold`. Försök gjordes även att optimera en RF med motsvarande strategi, men denna modell uppvisade sämre prediktionsprestanda än baseline och inkluderades därför inte i fas tre.

i fas 3 höjdes maxiterations till 1000, jämfört med 500 i fas 1. Detta gjordes för att undersöka om det ger tillräckligt utrymme att hitta valida lösningar vid olika threshold-nivåer.

3. Resultat


3.1 Resultat, fas 1: baseline-modeller och utforskning

Fas 1-experimenten visar tydliga skillnader mellan explainers, modeller och användningen och constraints. Random-search explainern uppvisade störst variation och var särskilt känslig i kombination med RF. Utan constraints misslyckades den att hitta genomförbara CFs i nästan hälften av observationerna, och validitet uteblev i flera fall. För XGB var random-search stabilare: validitet uppnåddes i samtliga observationer även utan constraints, men fyra av nio CFs var då inte genomförbara. Med constraints blev resultaten genomgående valida och genomförbara, men förändringarna koncentrerades nästan uteslutande till BMI (se Appendix C).

Tabell 3.3: Sammanfattande resultat – Generation 1

Explainer	Modell	Constraints	Validitet	Genomförbarhet	Körtid	Kommentar
random-search	RF	Ja	Medel	Hög	1028 s	Stabilare men långsam; vissa validitetsmissar
random-search	RF	Nej	Låg	Låg	301 s	Flera icke-genomförbara CF; validitet uppnås inte i vissa fall
random-search	XGB	Ja	Hög	Hög	435 s	Robust men nästan enbart BMI-förändringar.
random-search	XGB	Nej	Hög	Medel	134 s	Valid men ofta icke-genomförbara CF
genetic	RF	Ja	Hög	Hög	19 s	Snabb och stabil; varierande lösningar
genetic	RF	Nej	Medel	Låg	19 s	Några validitetsmissar; vissa icke-genomförbara CF
genetic	XGB	Ja	Medel / Hög	Hög	9 s	Snabbast; en observation utan validitet
genetic	XGB	Nej	Medel / Låg	Låg	11 s	Marginella BMI-förändringar räckte ej för att uppnå validitet

Figure 3.1: Resultat - generation 1



Den genetiska explainerns beräkninstid låg runt 9-19 sekunder oavsett constraints men XGB snabbare än RF. Andelen valida CFs är ganska stabil mellan 37-47%. Utan constraints förekom vissa observationer där validitet inte uppnåddes eller där förändringarna var så små att de inte kan betraktas som genomförbara. Med constraints genererades däremot valida och genomförbara CFs för nästan alla observationer, och förändringarna var mer varierande än i random-search-fallen. RF med genetic och constraints har löst alla observationer, medan XGB generar högre andel valida CFs, men som vars förändringar i sannolikheterna inte räckte för validitet i en observation.

Sammanfattningsvis visar resultaten att constraints är centrala för genomförbara CFs, att random-search är känslig för modellval. De fullständiga tabellerna för körningar med constraints finns i Appendix C.

3.2 Resultat, fas 2: Modelloptimering via SMOTE och viktning

Träningsstrategierna via klassviktning, SMOTE-balansering av datan, samt hyperparameteroptimerad SMOTE (grid-search), uppvisade genomgående låg validitet och i flera fall total avsaknad av valida CFs (lösta observationer %). Av de 18 testade konfigurationerna misslyckades 10 helt eller delvis. Ett framträdande mönster är `stopping_threshold`-värdet: `stopping_threshold 0.5` fungerade i samtliga fall, medan `stopping_threshold 0.1` misslyckades totalt och `stopping_threshold 0.9` mestadels misslyckades.

Tanken var ursprungligen att testa samtliga konfigurationer mot olika `stopping_threshold`-värden, men eftersom endast `stopping_threshold 0.5` producerade användbara resultat för SMOTE och viktade modeller, presenteras dessa istället på *Figur 3.2* nedan, grupperade på X-axeln som *SMOTE-bas*, *SMOTE-gridsökt* samt *viktade modeller*.

Prestanda och körtid: RF uppvisar som vanligt längre körtider (~90-140 sekunder), medan även den gridsearch-optimerade XGB på SMOTE-data har en total körtid på cirka 100 sekunder. ML-modellernas prediktioner ligger mellan ca 20-50%, med XGB något högre. Det finns en linjär utveckling av prediktionsnivåerna från SMOTE-bas modellerna (lägst), till SMOTE-gridsökta (medel) och till sist viktade modeller (högst).


Validitet och antal förändringar: validiteten är runt 40% vilket är godtagbart för SMOTE-baseline modellerna, men för de övriga är de mycket låga. RF-SMOTE baseline hittar de valida CF för de flesta observationerna (100% vid `stopping_threshold 0.5`), medan de andra i bästa fall löser hälften. Viktad RF löser ingen observation.

Gower Distans: Modellerna beter sig relativt lika vad gäller genomsnitt- och medianvärden på Gower, med undantag för viktade RF där data saknas för valida medelvärden. Gower-distans-trösklarna 0.02 (lågt) respektive 0.35 (høgt) används för att mäta om meningslösa CF-förändringar görs (lågt) eller stora (høgt)¹. Alla modeller har liten andel (%) låga Gower-värden (<0.02), där graferna i stort sett ligger på varandra. Vad gäller andel höga gower-värden (>0.35) är de även väldigt lika när man kollar på alla CF-genereringar – men när man kolla på enbart valida förändringar finns stora skillnader – Alla XGB har större andel med hög gower (~12-24, mot RF 8-0). Detta indikerar att XGB måste göra större förändringar för att få valida CFs och att de då ofta blir orimligt stora (störst uttryck hos viktad XGB), vilket den högre predicerade risken även visar. Detta beteende uppvisas inte av RF, men de lyckas inte heller lösa observationerna. Den viktade XGB har låg validitet (33%), men har trots det löst 56% av observationerna.

¹ Exempel på små och meningslösa CF-förändringar (Gower <0.02) gäller främst små BMI-förändringar på 0.01. Exempel på stora CF-förändringar (Gower >0.35) gäller exempelvis att gå från att röka dricka varje dag till att "aldrig ha druckit", sova helt utan sömnproblem, och "aldrig ha røkt".

Resultat av optimering: Hyperparameteroptimering via gridsearch (RandomSearchCV) försämrade resultaten. SMOTE-basmodeller hade 67% lösta fall, medan SMOTE-gridsökta endast uppnådde 33-50%. Detta tyder på att ökad modellkomplexitet eller överanpassning är kontraproduktivt för CF-generering, vilket diskuteras vidare i avsnitt 4.

Figur 3.2: Resultat för konfigurationer i fas 2 (SMOTE, viktade) som kunde generera CFs.




Sammanfattningsvis visar Fas 2 att SMOTE och klassviktning försämrar CF-generering kraftigt. Modellerna blir instabila, stopping_threshold misslyckas ofta och validiteten sjunker. Stabil sannolikhetsstruktur är viktigare än hög klassificeringsprestanda.

3.3 Resultat, fas 3: Prediktionsmodeller mot stopping_threshold

Här presenteras resultaten av två baseline-modeller (RF och XGB, samma som i fas 1), samt en hyperparameteroptimerad XGB. De tre modellerna jämförs mot tre olika stopping_thresholds (0.1, 0.5, 0.9), som presenteras på X-axeln i Figur 3.3 nedan.

Figur 3.3: Resultat - baseline-modeller och optimerad XGB mot stopping_threshold



Prestanda och körzeit: Som förväntat är RF mer än dubbelt så långsam som XGB (~24 sekunder vs ~10 sekunder). Baseline RF visar dock genomgående hög CF-genereringsförmåga med 100% solved rate över alla stopping_thresholds och validitet mellan 43-63%.

Prediktioner och riskreduktion: Modellernas initiala risk-prediktioner ligger lågt och relativt nära varandra. Den optimerade XGB har lägst prediktioner (~5%) jämfört med baseline RF och XGB (~10%), och uppvisar något högre riskreduktion. Detta mönster är konsekvent över alla stopping_thresholds.

Antal attributförändringar: Medelantal attributförändringar uppvisar liknande nivåer (2.0-2.3) för alla tre modeller över alla thresholds, med endast marginella skillnader. Däremot är medelantal ändringar för valida CFs konsekvent högre (2.2-2.5) än för alla genererade CFs, vilket tyder på att framgångsrik CF-generering kräver större attributförändringar.

Gower-distans: Gower-distanserna påverkas inte nämnvärt av `stopping_threshold` hos någon av modellerna, Baseline XGB uppvisar mest stabil Gower-profil över alla thresholds, medan RF visar något högre variation vid threshold 0.5.

Sammanfattningsvis visar Fas 3 att `stopping_threshold` styr om en CF hittas, men inte förändringstorleken. Baseline-modeller är stabilare och mer CF-vänliga än optimerade modeller, vilket understryker att kalibrering och stabilitet är centralt för CF-generering.

4. Diskussion

4.1 Constraints och explainers

Resultaten från fas 1 visar att constraints är nödvändiga för att generera genomförbara counterfactuals. Nackdelen är att körtiden ökar markant, vilket i praktiken påverkar valet av explainer. I den här studien blir den genetiska explainern nästan ett måste, just eftersom den hanterar den ökade körtiden betydligt bättre än random-search. Dock måste vi ställa frågan vilken explainer som har flest andel valida CFs och löser flest observationer. Här varierar det mellan kombinationer. Random-search + RF ger en låg andel valida CFs, och låg andel lösta observationer, medan XGB + random-search lyckas att hitta både valida och genomförbara CFs för samtliga observationer. Problemet är att i de flesta fall skedde förändringarna i en enda variabel (BMI). Därför är kombinationen XGB + random-search med constraints svår att rekommendera.

Med den genetiska explainern ligger modellerna betydligt närmare varandra. XGB ger något fler valida CFs, medan RF har högre andel lösta observationer (9/9, jämfört med 8/9). Med genetic är resultaten stabilare överlag. Sammantaget pekar fas 1 därför mot att den genetiska explainern i kombination med constraints är en kombination som är nödvändig, vilket också lades som grund för senare experiment i projektet. I nästa avsnitt följer en djupare diskussion om varför modellerna beter sig så olika.

4.2 Modellernas sannolikhetsstruktur (bagging vs boosting)

Resultaten från samtliga experimentfaser visar att modellernas interna sannolikhetsstruktur har en avgörande betydelse för hur effektivt DiCE kan generera CFs. Med sannolikhetsstruktur avses hur modellens predicerade sannolikhet förändras när input justeras. RF och XGB bygger sina prediktioner på två olika ensembleprinciper - bagging respektive boosting - vilket leder till olika sätt att förändra sannolikheter när en observation förändras.

Random Forest använder **bagging**, där många oberoende träd röstar om utfallet. Detta skapar en sannolikhetstruktur som ofta är **stegvis**: RF delar upp feature-rymden i diskreta regioner där varje region tilldelas en fast sannolikhet baserat på majoritetsröster. Sannolikheten förändras därför inte gradvis, utan hoppar upp eller ner när en observation hamnar i en ny region. I CF-sammanhang innebär detta att RF ibland kan hitta en valid CF genom en mycket liten förändring, eftersom ett litet steg kan räcka för att passera en regiongräns.

XGBoost behandlar samtliga variabler som kontinuerliga (flytpunkts-värden, istället för kategorier hos RF) och bygger sina prediktioner genom **boosting**. Boosting innebär att många små träd läggs till ett i taget och varje nytt träd korrigerar de fel som gjordes tidigare enligt en definierad loss-funktion. Detta skapar en **gradvis och mjuk sannolikhetsstruktur**. I CF-sammanhang betyder detta att XGB ofta kräver större justeringar i observationen för att nå en viss riskreduktion. Till skillnad från RF finns inga diskreta hopp som ger en stor riskminskning på en gång. För att nå samma riskreduktion som RF behöver XGB ofta flera små förändringar. Dessa ackumulerade justeringar blir snabbt för dyra för DiCE:s interna optimering, som strävar efter att ändra så få variabler som möjligt och hålla förändringarna små. Därför avbryts sökningen innan en valid counterfactual hittas.

Dessa skillnader illustreras tydligt för resultaten i observation 4 i fas 1, där både RF och XGB testades med constraints och den genetiska explainern. Trots att XGB modellen generellt uppvisade en något högre andel valida CFs i fas 1 misslyckades den med just denna observation, medan RF lyckades generera två valida CFs. XGB startade på en redan låg risknivå (0.07), vilket innebär att en en valid CF kräver en sänkning till 0.035. Vid 500 iterationer genererades endast 8 CF-förslag (av tio möjliga), och ingen av dem når halveringsmålet. Detta beror på att XGB:s gradvisa sannolikhetsstruktur gör det svårt att åstadkomma stora förändringar när sannolikheten redan är låg.

Något som ytterligare illustrerar ojämnheter i sannolikhetsstrukturen är att förändringar som intuitivt borde minska risken - exempelvis bättre sömn eller lägre BMI - i flera fall istället ökade riskvärdet (t.ex. CF 8 i tabell 4.1). Detta beror på att modellen rör sig i ett område nära en beslutsgräns, där små justeringar kan ge oväntade utslag. Det är inte nödvändigt så att hjärtsjukdom följer dessa variabler på ett enkelt eller linjärt sätt, och modellen speglar detta genom lokala variationer i sannolikheten.

Table 4.1. XGBoost: CFs och små sannolikhetsförändringar, observation 4, fas 1

CF id	etfruit	eatveg	smoking	alfreq	sleep	noise	BMI	do-sport	N-changed	valid	Risk before	risk after
Obs 4	3	3	6	6	2	0	24.34	1				
cf_1							24.33		1	False	0.065	0.07
cf_2				7			24.33		2	False	0.065	0.08
cf_3							24.33	4	2	False	0.065	0.08
cf_4							24.33	3	2	False	0.065	0.05
cf_5					1		24.33		2	False	0.065	0.06
cf_6							20.76		1	False	0.065	0.04
cf_7							23.64	3	2	False	0.065	0.15
cf_8					1		23.04		2	False	0.065	0.1

RF uppvisade större förändringar i risk vid CF-generering, även om själva feature-förändringarna i stort sett är likvärdiga. Trots att RF hade ett ännu lägre utgångsläge (0.02) lyckades den halvera risken genom mycket små förändringar. I CF 1 räckte en minimival justering av BMI för att sänka risken till 0.01, och i CF 5 gav en kombination av samma mindre BMI-förändring och tre dagar träning per vecka en risk på 0.00. Detta är ett direkt resultat av RF:s stegvisa sannolikhetsstruktur: en lite förändring i input kan råka flytta observationen över en regiongräns, vilket ger en stor sannolikhetsförändring. RF:s instabilitet blir här en fördel, eftersom modellen kan göra stora hopp som uppfyller halveringsmålet.

Table 4.2. RF: CFs och större sannolikhetsförändringar, observation 4, fas 1

CF id	etfruit	eatveg	smoking	alcfreq	sleep	noise	BMI	do-sport	N-changed	valid	Risk before	risk after
Obs 4	3	3	6	6	2	0	24.34	1				
cf_1							24.33		1	True	0.020	0.010
cf_2				7			24.33		2	False	0.020	0.033
cf_3							24.33	5	2	False	0.020	0.233
cf_4							24.33	4	2	False	0.020	0.020
cf_5							24.33	3	2	True	0.020	0.000
cf_6	2						24.33		2	False	0.020	0.123
cf_7							21.30		1	False	0.020	0.013
cf_8							23.84	6	2	False	0.020	0.136

Detta exempel visar att XGB:s "mjukare" sannolikhetsyta inte alltid är en fördel i CF-sammanhang. Vid låga låga utgångssannolikheter krävs ibland större hopp än vad boosting-strukturen kan producera. Modellen är stabil, snabb och förutsägbar, men ibland nästan för stabil, och de små trygga förändringarna blir helt enkelt för tröga för att nå halveringsmålet. I nästa fas blir kontrasten tydlig: där XGB i fas 1 är försiktig och gradvis, beter sig SMOTE- och viktade modeller snarare som "dopade" versioner av sig själva - med betydligt mer dramatiska variationer i sannolikheter, men också betydligt mindre förutsägbarhet.

4.3 Effekten av datamanipulation på sannolikheter

I fas 2 undersöktes olika strategier för att hantera obalanserad data - klassviktning, SMOTE och hyperparameteroptimering - påverkar möjligheten att generera valida CFs. Dessa metoder används ofta för att förbättra modellernas klassificeringsprestanda, framför allt recall för minoritetsklassen, och det framstod därför vara rimligt att inkludera dem i experimenten. En ytterligare motivation var att vissa observationer mycket låga predicerade riskvärden (t.ex. 0.02), vilket antogs göra halveringsmålet svårare att uppnå (även om motsatsen visade sig vara fallet). Syftet var därför att testa om en form av "upp-kalibrering" av risknivåerna skulle underlätta CF-genereringen. Samtidigt gav dessa experiment - tillsammans med resultaten i fas 3 - en möjlighet att mer generellt undersöka hur modellernas kalibrering samspelar med uvärderingsmätt och stopping_threshold, och därmed belysa samband som är relevanta även utanför just dessa experiment.

Resultaten visade att dessa metoder, trots att de kan höja recall, påverkar modellens sannolikhetsstruktur på ett sätt som inte är gynnsamt för CFs. När datan syntetiskt balanseras eller viktas lär sig modellen en artificiell klassfördelning snarare än de faktiska frekvenserna i datan. Sannolikheterna dras då mot mitten, även för observationer som baseline-modeller bedömde som låg risk. Modellen kan då inte längre reagera stabilt på små förändringar i input, och både halveringsmålet och stopping_threshold blir svårare att uppnå. Här blir skillnaden mellan relativ och absolut riskreduktion tydlig: att halvera en risk från 0.02 till 0.01 är en liten absolut förändring, men att pressa en syntetiskt upprägnad risk från ~0.5 ner till under 0.1 (som stopping_threshold 0.9 kräver) är en betydligt större absolut reduktion. Sammantaget visar fas 2 att det inte är modellens klassificeringsprestanda som avgör kvaliteten på counterfactuals. Tvärtom kan de försämra både

sannolikhetsstruktur och stabilitet, vilket gör att modellen reagerar mindre förutsägbart på små förändringar.

I kontrast till XGBoosts "försiktigt tassande" sannolikhetsyta i 4.2, beter som SMOTE- och viktade modeller snarare som modeller på steroider: mycket energi, mycket rörelse, men väldigt lite kontroll. För CF-generering behövs varken en modell som rör sig långsamt, eller en modell som hoppar runt okontrollerat, utan något däremellan. Hittills har baseline-RF legat närmast denna mittpunkt, även om den är något långsammare i sin körtid. Med detta i åtanke kan vi nu gå vidare och undersöka hur baseline-modellerna - och en försiktigt optimerad XGB-modell - placerar sig mot olika nivåer av DiCE:s `stopping_threshold`.

4.4 Effekten av `stopping_threshold`

`Stopping_threshold` införs i DiCE som ett sätt att anpassa counterfactual-genereringen till hur olika modeller faktiskt beter sig. Eftersom modeller kan vara olika kalibrerade och deras sannolikhetsfördelningar kan vara mer eller mindre ihoptryckta - exempelvis vid snedfördelade målklasser - behövs ett mål som definierar *hur mycket* risken måste sänkas för att en CF ska räknas som valid. Threshold-värdet är alltså ett sätt att styra var på modellen sannolikhetsyta DiCE får acceptera en lösning. Det blir särskilt tydligt i baseline-XGB, där fördelningen av prediktioner visar att modellen är starkt konservativ och nästan helt ihoptryckt mot låga sannolikheter.

Tabell 4.3: Sannolikhetsyta hos baseline XGB

Mått	Värde
Min prection	0.0000
Max prediction	0.9626
medel	0.1095
median	0.0643
95:e percentilen	0.3756

Den här fördelningen innebär att modellen i praktiken betraktar nästan hela populationen som lågrisk. Nästan alla observationer ligger under 0.4, och medianen runt 0.06 visar att modellen mycket sällan producerar höga sannolikheter. Vid `stopping_threshold` krävs att riskvärdet sänks till under 0.1. Eftersom baseline-XGB redan producerar mycket låga sannolikheter ligger många observationer nära denna nivå redan från början. Det innebär att endast små justeringar krävs för att nå målet, vilket passar XGBoost:s gradvisa sannolikhetsyta.

När vi går över till resultaten i fas 3 blir detta ännu tydligare. Baseline-XGB hamnar där i ett område av sannolikhetsytan där små justeringar räcker för att lösa alla observationer vid `stopping_threshold` 0.9². Samtidigt får Baseline-XGB mer förutsägbart högre Gower och fler ändringar när threshold höjs. Eftersom modellen bara gör små, gradvisa riskförändringar måste DiCE accumulera fler små steg föra att uppnå en större riskreduktion.

2 I fas 3 höjdes iterationsbudgeten för genetic explainern från 500 till 1000, vilket sannolikt är anledningen till att XGB lyckas hitta valida CFs i fas 3, med inte i fas 1. Iterationerna och antalet genererade CFs hade kunnat höjts ytterligare för att få en högre andel lösta observationer, en det hade samtidigt gjort jämförelsen mellan modeller och threshold-nivåer mindre rättvis och betydligt svårare att tolka. Lösningen för Observation 4 är etveg = 1, BMI = 24.3375. med *risk before* = 0.065, *risk after* = 0.0042.

Vid `stopping_threshold` 0.1 lyckas baseline-XGB bara producera en enda icke-valid CF för två observationer. Vid `stopping_threshold` 0.5 genereras tio CFs, men inte heller då uppnås halveringsmålet - trots att visa förändringar är större och involverar fler variabler. Först vid `stopping_threshold` 0.9 hittar modeller de förändringar som faktiskt halverar risken eftersom DiCE fokuserar på att hitta lösningar vars sannolikheter ligger under 0.1.

SMOTE- och viktade modellerna förstärker samma poäng. Genom att syntetiskt balansera klasserna dras sannolikheterna in mot mitten, runt 0.5. Det gör att modellen blir mindre säker i båda riktningar. Vid threshold 0.5 räcker en liten riskminskning för att nå målet, men vid 0.1 och 0.9 krävs mer extrema eller mer precisa riskförändringar än vad modellen kan producera. Threshold 0.5 blir därför ett naturligt "sweet spot" där modellens sannolikhetstruktur passa bäst.

Den försiktigt optimerade XGB-modellen placerar sig nära baseline-modellerna. Den har lägre andel validitet än baseline-XGB, men löser samtidigt fler observationer totalt sett. Den börjar dessutom från en lägre genomsnittslig risknivå, och reducerar mer risk i snitt. Även om skillnader här är små den också mindre stabil och förutsägbar: den varierar mer "hoppigt" över threshold-nivåerna. Det gör att jag här skulle rekommendera baseline-XGB framför den försiktigt optimerade varianten, eftersom baseline-modellen är något mer förutsägbar och därmed mer pålitlig i CF-sammanhang, då det är svårt att säga hur den optimerade modellen skulle reagera på andra observationer.

Mellan baseline-modellerna, RF och XGB, är skillnaderna vid `stopping_threshold` 0.9 små. Båda modellerna löser alla observationer och har samma andel validitet runt c:a 50%, och skillnaderna i Gower och antal ändringar är marginella. RF är något mer rörlig genom threshold-nivåerna och gör större sannolikhetshopp, medan den är samtidigt konsekvent genom alla `stopping_threshold` i att lösa alla observationer. XGB rör sig mer gradvis och ger jämnare kurvor, och den är dessutom betydligt snabbare att köra. I det här sammanhanget framstår baseline-XGB som det mer förutsägbara och effektiva alternativet, medan RF fortfarande är ett starkt val men något mindre smidigt på grund av sin längre körtid. En praktisk aspekt som också kan nämnas är att XGB-implementationen krävde lite mer handpåläggning i form av hantering av datatyper och konverteringar i pipelinen, medan RF fungerar direkt utan justeringar.

Sammantaget har experimenten i fas 3 gett en förståelse för hur `stopping_threshold` samverkar med prediktions-modeller och hur det bör implementeras i praktiken. Baseline-XGB:s prediktionspektrum i tabell 4.3 visar att threshold-värden måste förstås i relation till hur modellen faktiskt fördelar sina riskvärden: en modell som nästan uteslutande producerar låga sannolikheter reagerar helt annorlunda på threshold-krav än en modell med ett bredare spektrum. Detta väcker också frågan om hur man bör hantera observationer med hög utgångsrisk. En strikt `stopping_threshold` kan göra det svårt för observationer med hög utgångsrisk att uppnå validitet, och det påverkar dessutom Gower och diversity. När DiCE tvingas pressa risknivån längre ned krävs större eller fler förändringar, och samtidigt minskar sökutrymmet för varierade lösningar. I praktiska tillämpningar är det eventuellt rimligt att `stopping_threshold` vara dynamiskt anpassat efter modellens kalibrering och den aktuella observationens risknivå. Det kan eventuellt göra CF-genereringen mer robust i situationer där risknivåer varierar kraftigt mellan individer. Dess implementering ligger dock utanför ramen för denna studie och lämnas till vidare utveckling.

4.5 Metodologiska problem och begränsningar

Studien bygger på nio observationer ur datasetet, vilket innebär att resultaten inte är generaliserbara. Syftet var dock inte att dra statistiska slutsatser, utan att undersöka hur DiCE beter sig under olika modell- och parameterinställningar. Ett metodologiskt problem är att vissa variabler, framför allt

BMI dominerade både prediktionsmodellerna och de genererade CF-förslagen. Detta ledde ofta till mycket små och praktiskt irrelevanta förändringar, vilket illustrerar begränsningar i både datan och i DiCE:s optimeringsstrategi. Det är även svårt att avgöra vad som är realistiska eller praktiskt genomförbara förändringar när modellen föreslår större justeringar på flera enheter.

I efterhand framstår det också som problematiskt att BMI tilläts dominera både prediktionsmodellerna och CF-förslagen. Även om BMI var den statistiskt starkaste prediktorn i datasetet är det en grov och omdiskuterad indikator på hälsa, och större BMI-förändringar är varken snabba eller enkla att genomföra i praktiken³. Det finns även en kausilitetsproblematik: BMI kan sammanfatta flera andra livsstilsparametrar - exempelvis kost, fysisk aktivitet och sömn - som föregår en viktuppgång. När modellen föreslår att en individ ska "sänka sitt BMI" är det därför oklart vilken *faktisk livstilsförändring* detta motsvarar och CF-förslaget förlorar därmed en del av sin relevans. Ett alternativ hade varit att antingen begränsa eller frysa BMI i genereringen, eller att komplettera det med andra hälsomått för att minska ett ensidigt fokus på BMI.

Gower distansen har en central begränsning i detta sammanhang. Måttet behandlar alla features som likvärdiga och linjära, och saknar information om den praktiska eller beteendemässiga betydelsen av olika förändringar. En omfattande livsstilsförändring, så som att gå från 0 till 3 träningsdagar per vecka, blir likvärdigt motsvarande steg i att äta mer frukt eller grönsaker.

En variabel som förtjänar särskild uppmärksamhet är *pacnois* (bullerexponering). I det fullständiga ESS-datasetet varierar variabeln och modellen tilldelar den därför ett visst prediktivt värde. I de nio observationer som användes i CF-experimenten var dock *pacnois* konstant (värde 0). Dessutom är bullerexponering inte en genomförbar variabel i praktiken, eftersom individen i regel inte själv kan påverka sin omgivande ljudmiljö. I efterhand hade variabeln antingen kunnat exkluderas helt eller definieras som immutable (frost) i CF-genereringen. Det är också värt att notera att variabeln inte påverkade resultaten i någon större utsträckning. Det enda undantaget var i fas 1, där avsaknaden av constraints gjorde att DiCE ibland föreslog öknings i bullerexponering.

Ett centralt metodologiskt problem i denna studie är att prediktionsmodellen ibland tilldelar högre riskvärden till individer med till synes bättre levnadsvanor än till individer med sämre vanor. Detta leder i sin tur till att DiCE genererar CFs som framstår som ologiska eller direkt felaktiga ur folkhälsoperspektiv, exempelvis förslag om att öka alkoholkonsumtion eller BMI. Dessa fall illustrerar en grundläggande svårighet: modellen optimerar inte för medicinsk rimlighet, utan för att minimera sin egen predikterade risk baserat på de statistiska mönster som finns i datan. Det är därför nödvändigt att problematisera användningen av constraints. Å ena sidan behövs riktade constraints för att förhindra att modellen föreslår ohälsosamma förändringar. Å andra sidan riskerar constraints att dölja viktiga signaler i datan. Det är exempelvis möjligt att individer som tränar mycket, eller lever på ett sätt som uppfattar som "perfektionistiskt", samtidigt upplever hög stress, vilket i sin tur kan öka risken för hjärt-kärlsjukdom. Även om detta är spekulativt kan det inte uteslutas att modellen fångar upp sådana mönster. I sådana fall skulle constraints riskera att tvinga modellen bort från förändringar som faktiskt speglar underliggande samband i datan. Detta innebär att constraints både är nödvändiga och potentiellt snedvridande, vilket gör dem till ett centralt designval i implementeringen.

En ytterligare komplikation är att ESS-datan innehåller flera ordinala variabler där den lägsta kategorierna representerar tillstånd som inte är realistiskt reversibla. En individ som röker dagligen kan inte gå från "dagligen" till "aldrig någonsin ha rökt", eftersom svarsalternativen är formulerade utifrån ett livstidsperspektiv. Detta gör att vissa CFs blir teoretiska snarare än praktiskt genomförbara. Dessutom kan det finnas confounders som modellen inte kan särskilja, exempelvis att personer som röker eller dricker regelbundet kan också ha andra riskbeteenden eller sociala

3 Flera medicinska organisationer, bland annat American Medical Association (2023) betonar att BMI är ett grovt mått som bör användas med försiktighet och endast i kombination med andra indikatorer på hälsa.

omständigheter som påverkar hälsan på lång sikt. En CF-generator saknar denna kontextuella förståelse, till skillnad från en kliniker som kan väva in livshistoria, stressnivåer, sjukdomar i familjen (genetik) och andra faktorer som inte finns i datan.

Slutligen saknas i denna studie begränsningar för hur stora förändringar som är rimliga för varje individ. Att från att träna två dagar i veckan kan vara realistiskt för vissa, men inte för andra. Att införa individuella förändringssteg är både tekniskt och teoretiskt svårt, och låg utanför projektets tidsram. Detta innebär att vissa CF-förslag är matematiskt korrekta med praktiskt orimliga. Sammantaget visar det att constraints är nödvändiga för att undvika absurda CFs, men att de samtidigt introducerar nya problem som rör realism, individualisering och tolkning av modellens beteende.

4.6 Vidare utveckling

Resultaten i denna studie pekar på flera områden där projektet behöver vidareutvecklas innan CF-baserade rekommendationer kan användas i en praktisk applikation. Nedan sammanfattas de viktigaste utvecklingsstegen.

- **Variabelurval och datakvalitet**
 - Framtida arbete bör omfatta en systematisk genomgång av vilka variabler som är lämpliga för CF-generering i folkhälsodata. Vissa variabler är praktiskt opåverkbara (t.ex bullerexponering) och bör definieras som immutable, men andra - som BMI - är grova sammanfattande mått som riskerar att dominera både prediktioner och CF-förslag.
- **Större och mer varierande experiment:**
 - Utvärdera DiCE på fler observationer, inklusive individer med högre predikerad risk, och på andra dataset för att undersöka generaliserbarhet.
- **Sätta dynamiska värden på stopping_threshold:**
 - utveckla metoder för att anpassa stopping_threshold efter observationens utgångsrisk och modellens sannolikhetsfördelning, så att målnivån för riskreduktion blir rimlig även för individen med mycket höga eller mycket låga prediktioner.
- **Domänkunskap, constraints och alternativa distansmått**
 - CF generering i folkhälsodata kräver metoder som bättre speglar hur beteenden faktiskt kan förändras i praktiken. Framtida arbete bör därför utveckla mer sofistikerade constraints i samarbete med medicinska experter.
 - Samtidigt behövs distansmått som bättre fångar den faktiska betydelsen av förändringar. Varken DiCE:s kostnadsfunktion eller Gower-distansen har någon förståelse för "verkligheten" och behandlar alla variabler som linjära och likvärdiga. Det innebär att stora livsstilsförändringar i praktiken kan få samma betydelse som mindre förändringar.

Sammanfattningsvis så indikerar resultaten att ytterligare arbete krävs innan CF-baserade rekommendationer kan användas i en klinisk eller konsumentinriktad applikation. Särskilt behövs validering mot kliniska riktlinjer och expertbedömningar.

Referenser

Litteratur

American Medical Association. (2023). *AMA adopts new policy clarifying use of BMI in medicine*. AMA House of Delegates, juni 2023. Tillgänglig på: <https://www.ama-assn.org/press-center/press-releases/ama-adopts-new-policy-clarifying-use-bmi-medicine> (Hämtad: 20 maj 2026).

Lewis, D. (1975). *Counterfactuals*. Oxford: Blackwell.

Mothilal, R.K., Sharma, A. & Tan, C. (2020). Explaining machine learning classifiers through diverse counterfactual explanations. *Proceedings of the 2020 Conference on Fairness, Accountability, and Transparency*, s. 607–617. Tillgänglig på: <https://arxiv.org/abs/1905.07697> (Hämtad: 20 maj 2026).

Wachter, S., Mittelstadt, B. & Russell, C. (2017). Counterfactual explanations without opening the black box: Automated decisions and the GDPR. *Harvard Journal of Law & Technology*, 31(2), 841–887.

Dataset

European Social Survey. (2023). *ESS Round 11: European Social Survey Round 11 Data*. Tillgänglig på: <https://www.europeansocialsurvey.org> (Hämtad: 20 maj 2026).

Implementationer

Anteryd, J. (2026). *CF_bench* [Mjukvara]. GitHub. Tillgänglig på: https://github.com/Dyretna/cf_bench (Hämtad: 20 maj 2026).

Dandl, D. (2020). *counterfactuals* [Mjukvara]. GitHub. Tillgänglig på: <https://github.com/dandls/counterfactuals> (Hämtad: 20 maj 2026).

InterpretML Team. (2020). *DiCE: Diverse Counterfactual Explanations* [Mjukvara]. GitHub. Tillgänglig på: <https://github.com/interpretml/dice> (Hämtad: 20 maj 2026).

SeldonIO. (2020). *Alibi: Explainability Toolbox for Machine Learning* [Mjukvara]. GitHub. Tillgänglig på: <https://github.com/SeldonIO/alibi> (Hämtad: 20 maj 2026).

Tack

Jag vill rikta ett varmt tack till projektgruppen för stöd, idéer och värdefulla diskussioner under arbetets gång. Ett särskilt tack riktas till **Roozhin Heydari** på IT-högskolan i stockholm, vars tidigare arbete och kodbas utgjorde grunden för de experiment som vi tillsammans har vidareutvecklat i denna studie.

Tack även till **Assia Lebot** för nära samarbete, teknisk input och kontinuerligt stöd. Assias insatser under projektets senare del har varit särskilt betydelsefulla och kommer att bidra till det fortsatta arbetet efter denna studie.

Appendix A. Variabelbeskrivningar, skalor och observationer

Tabell A1. Variabelbeskrivningar

Namn	Beskrivning	Skala	Typ
etfruit	Frekvens - äta frukt	1–7 (1 = ofta, 7 = aldrig)	Prediktor
eatveg	Frekvens - äta grönsaker	1–7 (1 = ofta, 7 = aldrig)	Prediktor
cgtsmok	Frekvens - Rökning (cigaretter)	1–6 (1 = mycket, 6 = aldrig)	Prediktor
alcfreq	Frekvens - Alkoholkonsumtion	1–7 (1 = ofta, 7 = aldrig)	Prediktor
slprl	Frekvens - Sömnproblem	1–4 (1 = aldrig, 7 = alltid)	Prediktor
dosport	Träning, dagar per vecka	0-7	Predictor
BMI	Body mass index	kontinuerlig	Prediktor
paccnois	Bullerexponering i hemmiljön	Binär	Prediktor
hltprhc	Hjärt-kärlsjukdom	Binär	målvariabel

Tabell A.2: Skalor för variabler

Värde	etfruit / etveg	cgtsmok	alcfreq	slprl
1	Three times or more a day	Daily, ≥ 10 cig / day	Every day	None / Almost none
2	Twice a day	Daily, ≤ 9 cig / day	Several times / week	Several times / week
3	Once a day	I smoke but not daily	Once a week	Most of the time
4	< 1 / day but ≥ 4 / week	I don't smoke but used to	2-times / month	All / almost all
5	< 4 / week but ≥ 1 / week	Smoked a few times	Once a month	-
6	Less than once per week	Never smoked	< 1 / month	-
7	Never	-	-	-
77	Refusal	Refusal	Refusal	Refusal
88	Don't know	Don't know	Don't know	Don't know
99	No Answer	No Answer	No Answer	No Answer

BMI: kontinuerligt flyttal, behöver ej översättning.

dosport: antal dagar i veckan med fysisk aktivitet (0-7).

paccnois: buller i hemmiljön, binär variabel (1 = sant, 0 Falskt).

Värdena **77 (Refusal)**, **88 (Don't know)** samt **99 (No Answer)** har tagits bort i förbehandlingen för samtliga ordinala och binära variabler

Tabell A3. Observationer för experiment

	etfruit	etveg	cgtsmok	alcfreq	slprl	paccnois	bmi	dosport	hltprhc
Obs 1	4	3	3	4	2	0	18.99	0	0
Obs 2	3	4	1	2	3	0	22.38	0	1
Obs 3	5	3	1	1	4	0	22.69	7	0
Obs 4	3	3	6	6	2	0	24.34	1	0
Obs 5	5	4	2	7	1	0	21.26	3	0
Obs 6	2	2	1	2	4	0	27.99	0	0
Obs 7	2	3	5	4	1	0	27.68	4	0
Obs 8	2	3	6	3	1	0	20.44	2	0
Obs 9	6	4	1	1	1	0	26.01	0	1

Appendix B. Experimentmiljö och system-konfiguration

Systemspecifikationer

Samtliga experiment kördes på en Lenovo laptop med följande konfiguration:

Hårdvara

- **Processor:** AMD Ryzen 5 7535HS (6 kärnor / 12 trådar, upp till 4.6 Ghz)
- **RAM:** 16GiB
- **GPU:** Ingen dedikerad GPU användes (ingen CUDA-acceleration)
- **Cache:** L3-cache 16MiB

Operativsystem

- **Operativsystem:** EndeavourOS Linux (rolling release)
- **Arkitektur:** x86_64

Python-miljö

- **Python-version:** 3.11.13
- **Miljöhantering:** pyenv + virtualenv
- **Paketinstallation:** pip (requirements.txt i projektets repo)

Relevanta Python-paket

Endast de bibliotek som är centrala listas här. En fullständig lista finns i projektets *requirements.txt*

- `dice_ml` (0.12) – generering av counterfactuals
- `gower` (0.1.2) – beräkningar av gower-distance
- `imbalanced-learn` (0.14.1) – hantering av obalanserade klasser
- `numpy` (2.3) – numeriska beräkningar
- `pandas` (2.3+) - datahantering
- `scikit-learn` (1.8) – modelträning och utvärdering
- `xgboost` (3.1.2) – gradient boosting-modeller

Appendix C. Körningar för Generation 1

Tabell C.1: random-search + XGB, utan constraints (stopping_threshold 0.9, 10 genererade CFs, total körtid 133.85 s).

	etfruit	etveg	cgt-smok	Alc-freq	slprl	Pacc -nois	bmi	do-sport	Gentime sec	N-changed	Valid	Risk before	Predicted risk after	Expected	Comment
Obs 1	4	3	3	4	2	0	18.99	0	41.13						
cf_7	7		6							2	TRUE	0.03	0.0	FALSE	Fruit decrease
Obs 2	3	4	1	2	3	0	22.38	0	0.16						
cf_4				4						1	TRUE	0.25	0.08	TRUE	alcohol decrease
Obs 3	5	3	1	1	4	0	22.69	7	0.16						
cf_6							16.27			1	TRUE	0.22	0.01	TRUE	only bmi
Obs 4	3	3	6	6	2	0	24.34	1	48.81						
cf_4		1								1	TRUE	0.07	0.0	TRUE	fruits increase
Obs 5	5	4	2	7	1	0	21.26	3	42.86						
cf_1				3				5		2	TRUE	0.08	0.04	FALSE	alcohol increase
Obs 6	2	2	1	2	4	0	27.99	0	0.16						
cf_5							35.44			1	TRUE	0.05	0.02	FALSE	Bmi increase
Obs 7	2	3	5	4	1	0	27.68	4	0.18						
cf_4	5						30.62			2	TRUE	0.05	0.02	FALSE	Bmi increase, Fruit decrease
Obs 8	2	3	6	3	1	0	20.44	2	0.23						
cf_3	1						16.06			2	TRUE	0.06	0.0	TRUE	
Obs 9	6	4	1	1	1	0	26.01	0	0.16						
cf_8							16.21			1	TRUE	0.12	0.0	TRUE	only bmi

Kommentar: De CFs som valts ut för varje observation och visas i denna tabell är utvalda i post-processing genom att först filtrera på validitet, därefter på genomförbarhet (expected), och slutligen välja en CF slumpmässigt bland de återstående.

Tabell C.2: random-search + XGB, med constraints (stopping_threshold 0.9, 10 genererade CFs, total körtid 435.35 s).

	etfruit	etveg	cgt-smok	Alc-freq	slprl	Pacc - nois	bmi	do-sport	Gentime sec	Gower	N- changed	Valid	Risk before	Predicted risk after
Obs 1	4	3	3	4	2	0	18.9866	0	84					
cf_3							15.6601			0.1044	1	TRUE	0.026	0.004
Obs 2	3	4	1	2	3	0	22.3757	0	0.19					
cf_4				4						0.05	1	TRUE	0.2497	0.0782
Obs 3	5	3	1	1	4	0	22.694	7	0.23					
cf_8							20.7906			0.0357	1	TRUE	0.218	0.1046
Obs 4	3	3	6	6	2	0	24.3418	1	92.97					
cf_9							15.2866			0.125	1	TRUE	0.0653	0.0152
Obs 5	5	4	2	7	1	0	21.2585	3	92.58					
cf_5							21.2361			0.0009	1	TRUE	0.0811	0.0141
Obs 6	2	2	1	2	4	0	27.9904	0	0.2					
cf_2							20.2711			0.0819	1	TRUE	0.0484	0.0176
Obs 7	2	3	5	4	1	0	27.6817	4	42.04					
cf_4							26.1456			0.0179	1	TRUE	0.0539	0.0244
Obs 8	2	3	6	3	1	0	20.4382	2	122.97					
cf_4							20.1464			0.0068	1	TRUE	0.0565	0.0209
Obs 9	6	4	1	1	1	0	26.0146	0	0.18					
cf_5							19.8626			0.072	1	TRUE	0.1216	0.0039

Kommentar: Återstående fyra tabeller, ovan inkluderad använder constraints. Vi byter ut "expected" (alla är matematiskt genomförbara) mot "Gower" för att spara plats. Samma regler angående validitet, men vi väljer ut den CF med lägst Gower.

Tabell C.3: random-search + RF, med constraints (stopping_threshold 0.9, 10 genererade CFs, total körtid 1028.50 s).

	etfruit	etveg	cgt-smok	Alc-freq	slprl	Pacc - nois	bmi	do-sport	Gentime sec	Gower	N- changed	Valid	Risk before	Predicted risk after
Obs 1	4	3	3	4	2	0	18.9866	0	99.45					
cf_1							16.9409	3		0.1306	2	FALSE	0.0633	0.0967
Obs 2	3	4	1	2	3	0	22.3757	0	98.56					
cf_2				4			19.2603			0.1298	2	TRUE	0.1467	0.0267
Obs 3	5	3	1	1	4	0	22.6940	7	133.88					
cf_5	2									0.125	1	TRUE	0.1567	0.0733
Obs 4	3	3	6	6	2	0	24.3418	1	97.63					
cf_1							20.2869	2		0.1886	2	FALSE	0.02	0.08
Obs 5	5	4	2	7	1	0	21.2585	3	99.39					
cf_1							21.0769			0.0037	1	FALSE	0.0267	0.0167
Obs 6	2	2	1	2	4	0	27.9904	0	0.32					
cf_4								5		0.0893	1	TRUE	0.3267	0.0767
Obs 7	2	3	5	4	1	0	27.6817	4	100.37					
cf_5							25.6028			0.0298	1	TRUE	0.1467	0.0667
Obs 8	2	3	6	3	1	0	20.4382	2	398.59					
cf_5							19.8178			0.0275	1	TRUE	0.0133	0.0067
Obs 9	6	4	1	1	1	0	26.0146	0	0.32					
cf_6							24.2444	5		0.1516	2	TRUE	0.09	0.02

Tabell C.4: genetic + XGB, med constraints (stopping_threshold 0.9, 10 genererade CFs, total körtid 8.87 s).

	etfruit	etveg	cgt-smok	Alc-freq	slprl	Pacc -nois	bmi	do-sport	Gentime sec	Gower	N-changed	Valid	Risk before	Predicted risk after
Obs 1	4	3	3	4	2	0	18.9866	0	0.95					
cf_1							17.5842			0.0722	1	TRUE	0.026	0.003
Obs 2	3	4	1	2	3	0	22.3757	0	0.95					
cf_6					1		22.3757	1		0.1475	3	TRUE	0.2497	0.0691
Obs 3	5	3	1	1	4	0	22.6940	7	0.96					
cf_3				3	2		22.6757			0.25	3	TRUE	0.218	0.0426
Obs 4	3	3	6	6	2	0	24.3418	1	1.04					
cf_1							24.3375			0.0001	1	FALSE	0.0653	0.0653
Obs 5	5	4	2	7	1	0	21.2585	3	1.14					
cf_1							21.2585			0.1118	1	TRUE	0.0811	0.0141
Obs 6	2	2	1	2	4	0	27.9904	0	0.99					
cf_8				7			27.9904	6		0.4607	3	TRUE	0.0484	0.0193
Obs 7	2	3	5	4	1	0	27.6817	4	0.89					
cf_2							27.3308			0.0115	1	TRUE	0.0539	0.0267
Obs 8	2	3	6	3	1	0	20.4382	2	0.93					
cf_4							19.0523			0.0687	1	TRUE	0.0565	0.0067
Obs 9	6	4	1	1	1	0	26.0146	0	1.02					
cf_2							20.8991			0.1173	1	TRUE	0.1216	0.0256

Tabell C.5: genetic + RF, med constraints (stopping_threshold 0.9, 10 genererade CFs, total körtid 18.84 s).

	etfruit	etveg	cgt-smok	Alc-freq	slprl	Pacc - nois	bmi	do-sport	Gentime sec	Gower	N- changed	Valid	Risk before	Predicted risk after
Obs 1	4	3	3	4	2	0	18.9866	0	2					
cf_10				7			18.9745	7		0.2506	3	TRUE	0.0633	0.03
Obs 2	3	4	1	2	3	0	22.3757	0	2.1					
cf_9					1		22.3757	1		0.1475	3	TRUE	0.1467	0.05
Obs 3	5	3	1	1	4	0	22.6940	7	2.13					
cf_4				4	2		22.6757			0.1462	3	TRUE	0.1567	0.0633
Obs 4	3	3	6	6	2	0	24.3418	1	2.21					
cf_1							24.3375			0.0002	1	TRUE	0.02	0.01
Obs 5	5	4	2	7	1	0	21.2585	3	2.29					
cf_3			3				21.2585			0.1431	2	TRUE	0.0267	0.01
Obs 6	2	2	1	2	4	0	27.9904	0	2.12					
cf_1					1		27.9904			0.3357	2	TRUE	0.3267	0.0833
Obs 7	2	3	5	4	1	0	27.6817	4	1.98					
cf_2							25.5938			0.0572	1	TRUE	0.1467	0.0667
Obs 8	2	3	6	3	1	0	20.4382	2	1.97					
cf_4							19.4670			0.0631	1	TRUE	0.0133	0
Obs 9	6	4	1	1	1	0	26.0146	0	2.03					
cf_2	3			5			26.0044			0.1591	3	TRUE	0.09	0.0367